

**INSTITUTO FEDERAL DE EDUCAÇÃO,  
CIÊNCIA E TECNOLOGIA DO CEARÁ  
PROGRAMA DE PÓS-GRADUAÇÃO EM ENERGIAS RENOVÁVEIS**

**Henrique Bruno Oliveira Lima**

**ANÁLISE DA ASSINATURA ELÉTRICA PARA IDENTIFICAÇÃO DE  
CARGAS RESIDENCIAIS DE FORMA NÃO INTRUSIVA**

**Maracanaú, Ceará**

**2021**

Henrique Bruno Oliveira Lima

ANÁLISE DA ASSINATURA ELÉTRICA PARA IDENTIFICAÇÃO DE CARGAS  
RESIDENCIAIS DE FORMA NÃO INTRUSIVA

Dissertação apresentada ao Programa de Pós-graduação em Energias Renováveis do Instituto Federal de Educação, Ciência e Tecnologia do Ceará como requisito parcial para a obtenção do título de mestre em energias renováveis. Área de concentração: Energias Renováveis.

Prof. Dr. José Renato de Brito Sousa

Maracanaú, Ceará

2021

# Sumário

<b>1</b>	<b>INTRODUÇÃO</b>	<b>3</b>
<b>1.1</b>	<b>Justificativa</b>	<b>5</b>
<b>1.2</b>	<b>Objetivos</b>	<b>6</b>
1.2.1	Objetivo geral	6
1.2.2	Objetivos específicos	6
<b>2</b>	<b>FUNDAMENTAÇÃO TEÓRICA</b>	<b>8</b>
<b>2.1</b>	<b>Assinatura elétrica</b>	<b>9</b>
<b>2.2</b>	<b>Abordagens clássicas</b>	<b>10</b>
2.2.1	Máquinas de estado finito	10
2.2.2	Modelo oculto de Markov	11
<b>2.3</b>	<b>Estado da arte</b>	<b>12</b>
2.3.1	Redes Neurais	12
2.3.1.1	Denoising autoencoder (DAE)	13
2.3.1.2	Redes Neurais Recorrentes (RNN)	13
2.3.1.3	Sequência a sequência (seq2seq)	14
2.3.1.4	Sequência a ponto (seq2point)	14
2.3.1.5	OnlineGRU	14
<b>3</b>	<b>METODOLOGIA</b>	<b>16</b>
<b>3.1</b>	<b>Hardware de monitoramento</b>	<b>17</b>
<b>3.2</b>	<b>Captura de dados</b>	<b>17</b>
<b>3.3</b>	<b>Base de dados (dataset)</b>	<b>17</b>
<b>3.4</b>	<b>Implementação e análise</b>	<b>18</b>
<b>4</b>	<b>CRONOGRAMA</b>	<b>19</b>
<b>5</b>	<b>ORÇAMENTO</b>	<b>20</b>
	<b>REFERÊNCIAS</b>	<b>21</b>

# 1 Introdução

É crescente o número de pessoas preocupadas com o uso consciente de energia, seja pelo benefício financeiro ou pela preocupação com o impacto ambiental causado pela produção e consumo de energia, logo, a demanda por ferramentas que auxiliem na conservação e no uso eficiente de energia é crescente.

A conservação de energia, trata-se de evitar desperdícios e para se conservar a energia é fundamental que o cidadão receba informações relevantes e detalhadas, que o auxiliem a identificar falhas de eficiência em equipamentos e também que o façam perceber comportamentos que levam a desperdícios e assim induzindo-o a mudar hábitos, visando, portanto, a economia de energia. Sabe-se que, na maioria dos casos, uma grande parcela do desperdício de energia são causados pelos equipamentos utilizados, porém, no Brasil, as exigências relacionadas à eficiência energética se limitam a alguns poucos tipos de equipamentos, através do selo PROCEL, daí a importância de se conhecer o consumo de cada aparelho.

Para saber o consumo exato de um equipamento ou se ele está consumindo a mais do que foi projetado por conta de uma falha, geralmente, se faz necessário a instalação de sensores individuais em cada ponto de carga ou a utilização de medidores comerciais no ponto que se deseja fazer a medição, o que dificulta muito para o usuário final poder gerenciar seu consumo.

Já no caso de uma falha no fornecimento de energia da concessionária, o acionamento de fontes alternativas de energia, através de geradores ou o uso de baterias, são as opções mais comuns para manter uma residência abastecida de energia elétrica e a identificação de quais aparelhos estão consumindo naquele momento, teria, nesse caso, um custo elevado na implementação de sensores, que normalmente não é instalada nas configurações básicas dessas redes. Assim, a identificação e o acionamento de cargas prioritárias (geladeiras, freezers, luzes de emergência, etc.) nessa situação, quando configuradas, são de forma manual e suscetíveis a erros. Uma troca de equipamento de tomada já desconfigura o sistema. Tudo isso ocasiona a diminuição do tempo que essas fontes alternativas conseguem manter a residência funcional.

Já com a popularização de produtos relacionados a automação e o amadurecimento de sistemas que gerenciam todos os componentes de uma casa automatizada, a identificação individual de cargas elétricas é um ponto importante a ser melhorado e ter seus custos de implementação reduzidos. Identificação automática de cargas com seus consumos e prioridades, reconhecimento de padrões de consumo, identificação de presença sem sensores adicionais, monitoramento para segurança residencial, dentre outras funcionalidades, que

podem ser utilizadas nos sistemas de gerenciamento com essa identificação de cargas.

As informações de consumo de energia disponibilizadas pelas concessionárias são insuficientes para auxiliar aos consumidores na tomada de decisões que visem eficiência energética, pois, os medidores atuais das concessionárias só mostram o consumo total de energia elétrica, e, dado todo o exposto anteriormente, a discriminação do uso individual de cargas elétricas pode ser muito útil para diversos fins e, principalmente, para atingir a conservação e uso eficiente de energia.

A instalação de sensores individuais é o modo mais comum, mas também o mais custoso e intrusivo de monitoramento. Já no monitoramento não intrusivo de cargas, idealizado por Hart (1992), que nomeou esta técnica de NALM (Nonintrusive Appliance Load Monitoring), utiliza a instalação de apenas um sensor no painel de entrada de energia do consumidor (XU; MILANOVIĆ, 2015). Atualmente mais chamada de Non-Intrusive Load Monitoring System (NILM), é uma área de estudo que está crescendo bastante nos últimos anos, devido aos avanços dos métodos de aprendizado profundo e a criação de diversos datasets com dados reais de vários países (NILM WIKI, 2020). Desde projetos open source com dados para treinamento de inteligências artificiais, como o dataset ACS-F2, criado na Suíça com 225 eletrodomésticos e 15 categorias (RIDI; GISLER; HENNEBERT, 2014), até projetos com mais de 4 anos de captura de dados de residências reais, como o Dataport dos Estados Unidos, com 1200 residências e 70 categorias de equipamentos (NILM WIKI, 2020). Os pesquisadores estão começando a divulgar publicamente seus conjuntos de dados, permitindo que outros possam comparar suas abordagens com dados em comum.

A LIT-DATASET é uma base com dados com dispositivos brasileiros. Em desenvolvimento e disponibilizada em 2019 pela Universidade Tecnológica Federal do Paraná, mas diferente de bases mais completas, com dados coletados em um ambiente real, a base está sendo gerada, inicialmente, com dados sintéticos, atualmente com 26 dispositivos/cargas e suas combinações, e dados simulados (RENAUX et al., 2018 apud UTFPR, 2019).

Assim, através do monitoramento não intrusivo, da análise da assinatura elétrica e ao se comparar diferentes bases de dados e algoritmos existentes, outras variáveis podem ser analisadas e integradas para tentar facilitar a identificação individual de cargas residenciais. Dessa forma, o conhecimento do consumo individual de energia de cada dispositivo possibilitará ao consumidor conhecer seu padrão de consumo e assim identificar hábitos que podem ser alterados visando a conservação de energia, bem como também detectar falhas em equipamentos, além de diversas outras possibilidades que podem auxiliar sistemas de gerenciamento de redes elétricas inteligentes no contexto de uma casa inteligente, que vão desde medidas visando uma melhor eficiência energética até o monitoramento de pessoas em um ambiente.

## 1.1 Justificativa

É eminente a importância da desagregação da informação de uso de energia de cada equipamento elétrico e eletrônico conectado em uma residência, pois abre portas para uma série de benefícios para o usuário final, que vão desde o uso consciente de energia, a identificação de problemas nos equipamentos e até na diminuição de custos para a automatização residencial.

O modo mais comum de se fazer essa desagregação, é através da instalação de sensores de corrente em cada ponto de consumo de uma residência, porém, isso não é muito viável financeiramente, já que uma casa pode possuir dezenas de pontos de saída (tomadas e pontos de luz). Além de que, os equipamentos podem ser trocados de tomada, o que dificultaria a identificação. Neste modo de monitoramento intrusivo, os custos para detecção de pessoas em um ambiente, para segurança residencial na identificação de invasores ou automatização de processos em uma casa inteligente, seriam mais elevados, já que seria necessária a instalação de sensores de presença em todos os ambientes que se deseja fazer o monitoramento. Já no monitoramento não intrusivo de cargas, idealizado por Hart (1992), os custos com sensores são menores, visto que neste método utiliza apenas um sensor no painel de energia do consumidor.

Outra vantagem da desagregação das cargas residenciais, é a detecção de problemas elétricos em equipamentos, uma vez que estes, normalmente, só são identificados quando o equipamento tem uma parada total e isto poderia ser identificado de forma antecipada, através do monitoramento das cargas individuais que poderiam alertar sobre alterações na assinatura elétrica, logo, sem equipamentos de medição adequados, essa falha seria de difícil percepção pelo usuário comum.

Através do monitoramento individual das cargas de energia residencial, também é possível auxiliar ferramentas de gerenciamento de redes elétricas inteligentes na identificação de padrões no comportamento das pessoas, inclusive prever quando o usuário vai querer ligar o ar condicionado, a depender da temperatura, previsão do tempo e últimos usos, com essa informação poderá analisar e alterar as fontes de energia para a escolha do melhor custo benefício para aquele horário, além da identificação de prioridades das cargas de forma automática, mostrar ao usuário seus equipamentos com maior consumo para controle e um uso eficiente de energia, bem como também comparar o consumo entre equipamentos.

Fabricantes de eletrodomésticos e concessionárias de energia também poderiam se beneficiar dessa tecnologia. Utilizando uma frequência alta de capturas, seria possível identificar falhas de forma mais precisa nos equipamentos, ajudando no diagnóstico remoto e precoce. O fabricante com acesso a esses dados poderia acionar um técnico para a residência antes mesmo de o problema no aparelho se manifestar e assim reduzir os custos

com garantias, aumentando a vida útil do aparelho e reduzindo os impactos do descarte desses produtos de forma prematura no meio ambiente. Já as concessionárias, tendo o conhecimento exato de cada equipamento de uma casa, poderiam dimensionar melhor a energia para uma região e reduzir custos.

Portanto, são inúmeros os benefícios do monitoramento não intrusivo e da análise da assinatura elétrica das cargas residenciais, sendo assim, as principais contribuições deste trabalho serão possibilitar ao consumidor informações relevantes e discriminadas do uso individual das cargas elétricas, gerar informações que auxiliem ferramentas de gerenciamento de redes elétricas inteligentes na tomada de decisões, além de criar uma base de dados, a partir dos dados coletados de residências reais e assinaturas elétricas de diversos equipamentos elétrico e eletrônicos.

## 1.2 Objetivos

### 1.2.1 Objetivo geral

O objetivo principal deste projeto é a desagregação e análise da assinatura elétrica, através da implementação e comparação das diversas abordagens existentes, para identificação de cargas residenciais, seus consumos, previsão de falhas, identificação de pessoas em um ambiente, reconhecimento de padrões de uso, dentre outras possibilidades. Além da criação de uma base de dados nacional com a assinatura elétrica de diversos dispositivos e dados energéticos de residências reais.

### 1.2.2 Objetivos específicos

Para atingir o objetivo geral deste trabalho, foram estabelecidas metas inerentes a cada etapa do processo. Para a etapa das definições das configurações de hardware, foram definidos os seguintes objetivos específicos:

- Realizar testes para a escolha da melhor frequência de captura de dados, de um conversor analógico digital (ADC) e do hardware para a captura e o tratamento inicial dos dados.
- Montar o dispositivo para monitorar o consumo, através de sensores de corrente e tensão e instalar no quadro geral de uma residência.

Este dispositivo terá como objetivo capturar os dados e enviar para um servidor, onde as informações serão analisadas, em tempo real, através de algoritmos de inteligência artificial. Logo, para essa etapa de captura e análise dos dados, foram definidos os seguintes objetivos específicos:

- Capturar dados da assinatura elétrica de equipamentos mais comuns nas residências brasileiras, de forma sintética, com o hardware a ser desenvolvido e comparar com os resultados com aparelhos de medição comerciais para validação.
- Capturar dados do consumo total do laboratório e de três residências em ambiente real. Comparar resultados entre aparelhos de medição comerciais e o hardware a ser desenvolvido para validação.
- Criar um novo conjunto de dados (dataset) com as assinaturas elétricas capturadas nas etapas anteriores, para uso neste estudo e para servir de modelo para trabalhos futuros com inteligência artificial.
- Implementar, treinar, validar e comparar os algoritmos existentes, utilizando base de dados própria e/ou de terceiros, inicialmente com o kit de ferramentas (toolkit) NILMTK (NILMTK, 2020).



## 2 Fundamentação teórica

Para a identificação de cargas residenciais, é importante conhecer as assinaturas elétricas de cada dispositivo, mas a análise dessas assinaturas é uma atividade bastante complexa, pois diversas variáveis devem ser consideradas nessa análise. Na Figura 1, temos o exemplo de como as potências somadas se apresentam, com uma geladeira e um forno elétrico operando simultaneamente. Isso também mostra como o sinal é normalmente complexo e os aparelhos sempre operam ao mesmo tempo de outras assinaturas, por exemplo as luzes e aparelhos em espera (stand by).




Figura 1 – Carga de energia elétrica agregada ao longo do tempo. Fonte: HART (1992).

Outra variável a ser considerada nessa análise é que o uso da energia em uma determinada região tende a seguir um certo padrão de consumo, por exemplo, dependendo da temperatura, época do ano e até do IDH da região, a probabilidade de uso de determinados equipamentos, naquele horário específico, pode aumentar. Na Figura 2, temos um exemplo de consumo discriminado por carga consumidora ao longo do dia.

Assim, para o desenvolvimento deste trabalho é imprescindível entender sobre a assinatura elétrica, como também sobre as principais abordagens utilizadas atualmente no monitoramento não intrusivo de cargas, que serão apresentados nos tópicos a seguir.

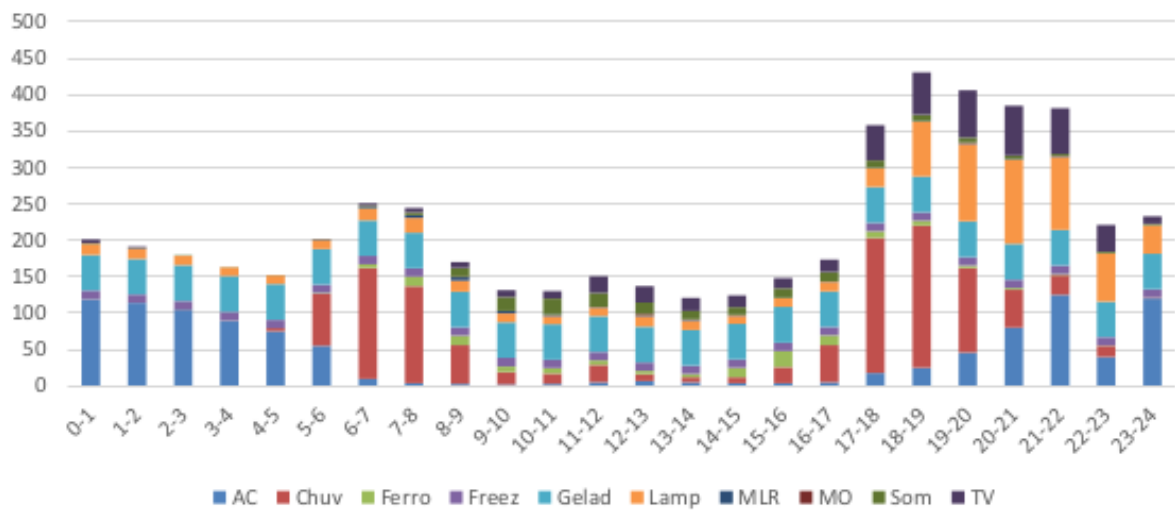


Figura 2 – Cargas consumidoras ao longo do dia. Fonte: TOMÉ (2014)

## 2.1 Assinatura elétrica

A assinatura elétrica é a característica única de cada carga e pode ser representada como um registro chave contendo vários atributos para avaliação e identificação. Os atributos presentes na assinatura elétrica de cada carga estão relacionados com o modo de operação em regime permanente e regime transitório no domínio do tempo e da frequência (MONZANI, 2016). Na Tabela 1, temos as classificações do modo de operação de cargas residenciais.

Tabela 1 – Modos de operação de cargas residenciais

Tipo de Carga	Exemplos	Eventos	Demanda de Potência
Estado único	Lâmpadas incandescentes, torradeiras, chuveiro elétrico.	$ON = OFF$	Plana
Variação contínua	Geladeira; freezer.	$ON \neq OFF$	Variante
Estados múltiplos	Máquina de lavar; aquecedor.	Eventos múltiplos	Variante ou plana

Fonte: MONZANI (2016)

Cargas de estado único, que ligam ou desligam a qualquer momento, possuem um alto valor de componente resistiva, ou seja, a potência ativa consumida é constante; Cargas de estados múltiplos, com tipos distintos de estados ligados, por exemplo, encher, enxaguar, centrifugar, bombear, secar, etc; Cargas variáveis continuamente, com uma faixa contínua de estados ligados, são mais difíceis de monitorar de forma não intrusiva, porque não geram mudanças graduais na potência. Exemplos desses tipos de cargas estão

demonstradas na Figura 3.



Figura 3 – Tipos de cargas variantes no tempo. Fonte: MONZANI (2016).

Já os grupos de cargas residenciais, de acordo com Sultanem (1991), podem ser classificados como na Tabela 2.

Tabela 2 – Grupos de cargas residenciais

Grupo	Característica	Exemplo
<b>Resistivo</b>	Potência reativa nula Transitório reduzido ou nulo.	Lâmpadas incandescentes, chuveiros elétricos, ...
<b>Motores de bombeamento</b>	Potência reativa significativa Transitório de partida elevado.	Motores de geladeira, freezer, máquinas de lavar.
<b>Motorizado</b>	Potência reativa Transitório de partida inferior.	Ventiladores, multiprocessadores, ...
<b>Eletrônicos</b>	Chaveamento e componentes harmônicas elevadas.	Computadores, televisores, monitores, ...
<b>Controle de potência eletrônico</b>	Variam de acordo com a potência em que operam.	Aspiradores de pó, fogões.
<b>Lâmpadas fluorescentes</b>	Transitórios longos, alta geração de terceiro harmônico.	Lâmpadas fluorescentes.

Fonte: MONZANI (2016).

## 2.2 Abordagens clássicas

Neste tópico será exposto um resumo das principais abordagens utilizadas atualmente no monitoramento de cargas de forma não intrusiva.

### 2.2.1 Máquinas de estado finito

A abordagem mais popular proposta por Hart (1992) foi quebrar a desagregação de energia em estágios de detecção de eventos. A ideia era detectar a comutação liga-desliga e fazer um rastreamento com uma máquina de estado finito (FSM), tentando subtrair a diferença entre a energia FSM e a carga agregada da casa (MARTIN, 2019). Esta técnica

requer informação referente ao padrão de consumo de cada eletrodoméstico existente na habitação, o que se faz necessário uma fase de treino. O algoritmo de Hart possui algumas limitações, ele não considera cenários onde diversos eletrodomésticos possam mudar de estado durante o mesmo período temporal, o que pode se tornar frequente em medições de baixa frequência (Reyes Lua, 2015).

$$\hat{a}(t) \approx \arg \min_a \left| P(t) - \sum_{i=1}^n a_i P_i \right|.$$

Figura 4 – Critério de minimização para a abordagem FSM. Fonte: HART (1992).

### 2.2.2 Modelo oculto de Markov

Um modelo oculto de Markov é um modelo estatístico em que o sistema modelado é assumido como um processo de Markov com parâmetros desconhecidos, e o desafio é determinar os parâmetros ocultos a partir dos parâmetros observáveis. Baseando-se na Máquina de Estado Finito (FSM), foi introduzido o conceito de que um estado para uma variável no modelo depende de seu estado anterior, bem como potencialmente os estados de outras variáveis no modelo. Isso significa que a mudança do estado de uma chaleira de desligada para ligada depende se ela estava ligada ou desligada anteriormente, além de depender se a torradeira está ligada ou desligada, por exemplo (MARTIN, 2019).




Figura 5 – Modelo Fatorial de Markov Oculto, mostrando como as observações dependem de uma série de estados ocultos  $S^1..S^m$ , em que cada um depende de seus próprios estados anteriores. Fonte: FAUSTINE et al. (2017).

## 2.3 Estado da arte

O método de desagregação de cargas de forma não intrusiva, proposto por Hart no início da década de 1980, teve um crescimento importante nos últimos anos impulsionado pelos esforços para a conservação de energia, redução de emissões, pela evolução computacional e o aumento na implantação de medidores inteligentes em todo o mundo. Este crescimento da área levou os pesquisadores a implementar vários algoritmos para resolver o problema de desagregação de energia, envolvendo redes neurais, big data e métodos estatísticos, como mostrado na Figura 6.



Figura 6 – Estado da arte das técnicas de desagregação de energia. Fonte: VERMA et al. (2021).

No final do ano de 2019, uma API chamada nilmtk-contrib, complemento para o toolkit de código aberto para monitoramento de carga não invasivo (NILMTK), foi criada com o objetivo de facilitar as comparações dos diferentes algoritmos que executam a desagregação de energia, analisar e padronizar os conjunto de dados disponíveis e disponibilizar um benchmark de referência para implementações dos algoritmos (BATRA et al., 2019). Essa API diminui a quantidade de conhecimentos básicos necessários para desenvolvedores de algoritmos e abre caminho para comparações entre as abordagens. Os algoritmos de redes neurais listados a seguir, já possuem implementação no nilmtk-contrib.

### 2.3.1 Redes Neurais

As redes neurais foram aplicadas com sucesso a uma série de cenários e alcançaram bons resultados, inclusive na generalização de casas fora do treinamento (KELLY; KNOTTENBELT, 2015; HE; CHAI, 2016). Os algoritmos de redes neurais empregados

com maior sucesso são as redes neurais recorrentes (RNN) e a Long Short Term Memory (LSTM).

#### 2.3.1.1 Denoising autoencoder (DAE)

Os autocodificadores são um conjunto de conceitos de aprendizado de máquina não supervisionados que resultam na redução da dimensionalidade inerente dos dados projetados, preservando suas características essenciais e permitindo que os dados de uma dimensão superior sejam sintetizados em uma dimensão inferior usando a transformação não linear. É composto por duas funções, especificamente, codificador e decodificador (VERMA et al., 2021). Para seu uso em NILM, o sinal da rede elétrica é tratado como um sinal de energia do aparelho ruidoso e o sinal da rede é considerado a soma da energia total consumida pelo aparelho alvo e algum ruído adicional. Como o DAE desativa um aparelho por vez, ele precisa de vários modelos treinados para que um grupo de aparelhos seja desagregado. Além disso, neste cenário, o DAE obtém como entrada uma janela das leituras da rede (a duração da janela de tempo permanece fixa) e produz os valores de consumo induzido do aparelho para a mesma janela de tempo da saída.

#### 2.3.1.2 Redes Neurais Recorrentes (RNN)

Redes neurais recorrentes são um conjunto de algoritmos comumente usados para predição de séries temporais, processamento de linguagem natural e outras consultas de processamento de sequência. Elas lidam com os elementos de entrada um por um e retém todos os estados encontrados anteriormente. O algoritmo funciona salvando a saída de um estado e devolvendo-a à camada de entrada que a carrega para previsões posteriores (VERMA et al., 2021). Portanto, cada elemento do modelo leva em consideração não apenas as entradas atuais, mas também o que ele lembra dos elementos anteriores. Reter a memória de estados anteriores dá a ele a capacidade de aprender uma dependência de longo prazo, processando uma série de eventos e manipular todo o contexto de uma vez para fazer uma previsão. Manter as informações em toda a rede deixa os RNNs com algumas desvantagens, pois trazem o problema de desaparecimento e explosão de gradientes. Uma vez que os gradientes são os portadores básicos de informações no RNN, eles às vezes podem acumular informações excessivas que podem até conter erros, ou podem se tornar extremamente pequenos, tornando as atualizações de parâmetros insignificantes. Uma atualização de parâmetro muito alta para o modelo neural pode sobrecarregá-lo desnecessariamente e outras notavelmente pequenas podem torná-lo ineficaz. Uma solução para esse problema é o uso de células de memória que podem salvar um estado e manter um transporte para minimizar a perda de informações durante o processamento da sequência. Essas células são chamadas de LSTMs (Long Short Term Memory). Elas também tem uma estrutura em forma de cadeia, mas com várias camadas de rede neural de comunicação que decidem a quantidade de dados que devem ser retidos, a importância dos dados a

serem lembrados e a parte da célula de memória que impacta a saída no dado intervalo de tempo. Além disso, os RNNs funcionam bem para dados sequenciais como no caso do NILM, pois permitem conexões de neurônios na mesma camada da rede neural. O modelo RNN empregado é alimentado com uma sequência de leituras da rede como entrada e produz um único valor de saída que dá a potência consumida pelo aparelho em teste. A rede também utiliza algumas unidades de memória de longo prazo (LSTM) e armazena valores nas células de memória embutidas para superar o problema de desaparecimento de gradientes.

### 2.3.1.3 Sequência a sequência (seq2seq)

O modelo de aprendizado de sequência a sequência é um conceito de aprendizado profundo usado para converter uma sequência em outra. Ele contém um codificador RNN para entender a sequência de entrada e um decodificador RNN para decodificar o vetor, construindo assim uma sequência de saída. Há um conjunto de RNNs que operam comumente entre o codificador e o decodificador. A cada etapa de recorrência na rede do codificador, uma nova palavra é fornecida à entrada, que é utilizada na etapa subsequente pelo próximo estado. Uma vez que o decodificador recebe o estado final do codificador, aplica uma distribuição de probabilidade discreta (para a entrada em cada etapa) para prever a saída levando em consideração uma função de perda. O modelo aqui tenta mapear a sequência de leitura da rede elétrica para a sequência do dispositivo de destino, aprendendo um mapa regressivo entre eles. O modelo seq2seq usa uma expressão de regressão que é definida por  $x_t : t + W/1 = f(Y_t : t + W/1, Q) + E_t$ , onde  $f$  é uma rede neural.

### 2.3.1.4 Sequência a ponto (seq2point)

O modelo seq2point opera modificando a entrada de rede recebida para funcionar como uma janela principal, enquanto a saída para o dispositivo de destino aparece funcionando no ponto médio de sua janela. Esse ponto médio deve ser correlacionado com as informações do sinal de rede recebido, antes e depois do momento em que ele ocorre. Esta técnica de treinamento também pode ser considerada uma regressão não linear.

### 2.3.1.5 OnlineGRU

A OnlineGRU é uma nova geração de Redes Neurais que substituem as unidades LSTM por Gated Recurrent Units (GRU) mais leves, diminuindo assim os requisitos computacionais e ao mesmo tempo em que oferece desempenho equivalente. Eles também tentam reduzir a redundância otimizando os tamanhos de camadas recorrentes, bem como minimizando o risco de desaparecimento de gradientes. Os GRUs são dotados de um mecanismo interno denominado gates, que é capaz de regular o fluxo de informações e fornecer uma solução eficaz para a memória de curto prazo. Essas portas funcionam

passando informações para a longa cadeia de sequências à medida que aprendem qual parte dos dados é importante. GRUs são semelhantes aos LSTMs, exceto que eles não têm um estado de célula e, em vez disso, usam o estado oculto para transferência de informações. Eles geralmente contêm duas portas, uma porta de reinicialização determina quanto do conhecimento passado deve ser esquecido, enquanto a porta de atualização decide que parte das informações deve ser descartada e quais novas informações devem ser adicionadas à unidade. Se a porta de reinicialização se aproximar de zero, o estado oculto é forçado a desconsiderar seu estado e é resetado com a entrada atual. Isso permite que o estado oculto descarte qualquer informação considerada insignificante no futuro. Este resultado permite uma representação mais compacta. Já a porta de atualização controla a quantidade de informações do estado oculto anterior que será trocada para o estado oculto atual. A atuação da GRU em um momento específico pode ser uma adição direta entre a atuação passada e a ativação candidata, onde uma porta atualizada escolhe quanto a unidade revisará sua ativação ou conteúdo. O modelo GRU online para NILM, recebe como entrada, as leituras de rede disponíveis mais recentes do aparelho de teste  $Y_t : t + W/1$  e emite o consumo de energia calculado  $x_j(t + W/1)$  do aparelho no teste  $j$ , para o último ponto no tempo.



### 3 Metodologia

Para atingir os objetivos deste projeto, o trabalho ocorrerá em três etapas, a primeira será a realização de testes com a finalidade de montar um hardware de monitoramento. Depois de validado o dispositivo, segue para a execução da etapa de captura de dados das assinaturas elétricas de equipamentos de modo sintético e, com o dispositivo instalado no quadro geral, para o monitoramento não intrusivo das residências. Na terceira etapa, com os dados capturados, será realizada a desagregação e análise das assinaturas elétricas, através da implementação, treinamento, validação e comparação dos algoritmos existentes de desagregação e classificação e criado um banco de dados que servirá para este trabalho e também para estudos futuros. Na Figura 7 é apresentado o diagrama da metodologia proposta.

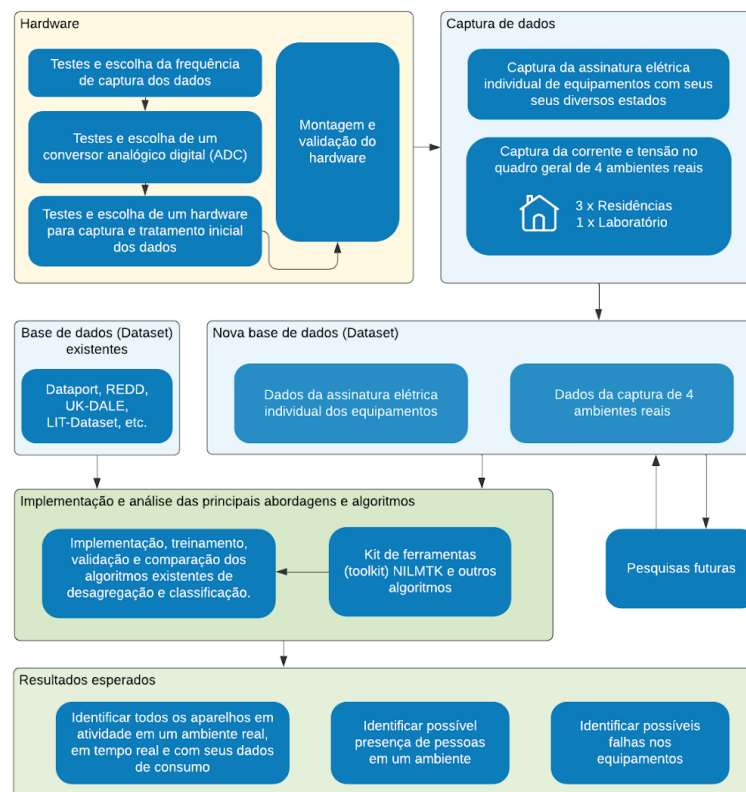


Figura 7 – Diagrama da metodologia proposta. Fonte: O autor (2020).

Cada uma dessas etapas da metodologia de trabalho proposta e apresentadas no diagrama supracitado, estão descritas nos tópicos a seguir.

### 3.1 Hardware de monitoramento

Para a montagem do hardware de monitoramento de consumo, serão necessários testes e pesquisas para a escolha da melhor frequência de captura de dados, de um conversor analógico digital e de um hardware para a captura e processamento inicial dos dados. A validação do hardware se dará pela comparação dos seus resultados com a de medidores comerciais. Serão montados 4 dispositivos de captura.

Nos testes para a escolha da melhor frequência de captura de dados, deve-se levar em consideração que as frequências altas podem necessitar de um hardware de maior capacidade para fazer o processamento das informações e frequências baixas podem dificultar a identificação das cargas e detecção de problemas.

Para os testes com a finalidade de escolher um conversor analógico digital (ADC) de alta ou baixa velocidade, alguns tipos podem ser considerados, como por exemplo: ADS7945/6 (14-bit, 2 MSPS), AD9201 (10-bit, 80 MSPS), ADS1115 (16-bit, 860 SPS), ADC1061 (16-bit, 860 SPS) ou até mesmo o ADC do ATmega328.

E, por fim, nos testes com um hardware para captura e o tratamento inicial dos dados, serão utilizados inicialmente três tipos, que poderão ser um computador (PC), um BeagleBone e um arduino.

### 3.2 Captura de dados

A captura de dados será realizada em duas etapas, que podem ocorrer de forma simultânea. A primeira será a captura da assinatura elétrica individual de diversos equipamentos elétricos e eletrônicos, mais comuns nas residências brasileiras, com seus vários estados, para a construção de uma base de dados que servirá para o treinamento dos algoritmos.

A segunda etapa será a captura, diretamente no quadro geral e de forma ininterrupta, da corrente e tensão de três residências e do laboratório de pesquisas do IFCE, Campus Fortaleza.

### 3.3 Base de dados (dataset)

Os dados capturados, das assinaturas elétricas individuais de cada equipamento e dados energéticos dos quatro ambientes reais, monitorados de forma ininterrupta por pelo menos 1 ano, serão utilizados para a construção de um novo conjunto de dados (dataset), que será utilizado para esse estudo e para servir de modelo para estudos futuros com inteligência artificial na área energética no país.

Base de dados já existentes, de terceiros (por exemplo, Dataport, REDD, UK-DALE, LIT-Dataset, etc.), também serão utilizadas no projeto para efeito de comparação dos resultados das diversas abordagens e em relação ao novo conjunto de dados.

### 3.4 Implementação e análise

A implementação, treinamento, validação e comparação dos algoritmos existentes de desagregação e classificação, terá como ponto de partida o kit de ferramentas NILMTK. O NILMTK é um toolkit de código aberto projetado para ajudar os pesquisadores a avaliar a precisão dos algoritmos de NILM, através da comparação de algoritmos de desagregação de energia (NILMTK, 2020). Ele inclui uma coleção de algoritmos de pré-processamento e um conjunto de ferramentas estatísticas para auxiliar na comparação entre os algoritmos.

Os principais algoritmos implementados no toolkit são: Combinatorial optimisation, factorial hidden Markov model (FHMM), George Hart's 1985 disaggregation algorithm, Maximum Likelihood Estimation e Latent Bayesian Melding (Mingjun Zhong). A base de dados a ser construída será em um formato compatível para ser usada e integrada no NILMTK. Outros algoritmos, principalmente os citados nas principais abordagens utilizadas atualmente, e que não estão implementados no NILMTK, também serão testados, se disponíveis, para fins de comparação.

Os dados serão analisados e tratados visando a identificação de cargas residenciais, os seus consumos, a previsão de falhas, a identificação de pessoas em um ambiente, o reconhecimento de padrões de uso, dentre diversas outras possibilidades.

## 4 Cronograma

Tabela 3 – Cronograma de atividades a serem realizadas nos anos de 2021 e 2022

Atividades	2021						2022						
	Jul	Ago	Set	Out	Nov	Dez	Jan	Fev	Mar	Abr	Mai	Jun	Jul
Levantamento bibliográfico	X	X	X	X	X	X	X	X	X	X	X		
Testes, montagem e validação do hardware de monitorando	X	X	X										
Captura, comparação e validação dos dados da assinatura elétrica de diversos equipamentos	X	X	X	X									
Captura dos dados energéticos das residências e do laboratório	X	X	X	X									
Implementação, treinamento, validação e comparação dos algoritmos existentes				X	X	X	X						
Análise dos dados					X	X	X	X	X	X	X		
Redação do trabalho					X	X	X	X	X	X	X		
Entrega da qualificação							X						
Revisão e redação final									X	X	X	X	
Entrega do trabalho aos membros da banca												X	
Defesa da dissertação													X

Obs: Este cronograma pode sofrer alterações no decorrer da elaboração da pesquisa

## 5 Orçamento

Tabela 4 – Estimativa de recursos financeiros e de infraestrutura

Equipamentos	Descrição	Quantidade	Valor Unitário (R\$)	Valor Total (R\$)
Sensores de corrente não invasivo	SCT-013 <sup>1</sup>	8	R\$ 50,00	R\$ 400,00
Sensores de tensão CA	0 a 250V (ZMPT101B) <sup>1</sup>	8	R\$ 25,00	R\$ 200,00
Conversor analógico digital (ADC)	ADS7945/6, AD9201, ADS1115, ADC1061	5	R\$ 10,00	R\$ 50,00
BeagleBone	Black Revisão C	2	R\$ 350,00	R\$ 700,00
Arduino	Uno R3 <sup>2</sup>	1	R\$ 60,00	R\$ 60,00
Computador	8 cpus e 8 GB de memória <sup>2</sup>	1	R\$ 1.500,00	R\$ 1.500,00
Alicate amperímetro	Minipa ET-4080 <sup>2</sup>	1	R\$ 1.500,00	R\$ 1.500,00
Medidor de qualidade de energia	Homis HAE-303 <sup>2</sup>	1	R\$ 20.000,00	R\$ 20.000,00
Multímetro digital	Minipa ET-2042D <sup>2</sup>	1	R\$ 250,00	R\$ 250,00
<b>Total (R\$)</b>				1.125,00 <sup>3</sup>

<sup>1</sup> Parcialmente disponível no laboratório.

<sup>2</sup> Disponível no laboratório.

<sup>3</sup> Valor total desconsiderando itens já disponíveis no laboratório.

Todos os custos serão arcados pela pesquisadora, não trazendo nenhum ônus para a Instituição que contribuirá com a pesquisa, orientadores e participantes.

Fortaleza \_\_\_\_\_ de \_\_\_\_\_ 2021

---

Henrique Bruno Oliveira Lima

# Referências

- ABUBAKAR, I. et al. Application of load monitoring in appliances' energy management – A review. **Renewable and Sustainable Energy Reviews**, Elsevier, v. 67, p. 235–245, 2017. ISSN 18790690. Disponível em: <http://dx.doi.org/10.1016/j.rser.2016.09.064>.
- BARSIM, K. S.; MAUCH, L.; YANG, B. Neural Network Ensembles to Real-time Identification of Plug-level Appliance Measurements. 2018. Disponível em: <http://arxiv.org/abs/1802.06963>.
- BARSIM, K. S.; STREUBEL, R.; YANG, B. An Approach for Unsupervised Non-Intrusive Load Monitoring of Residential Appliances. **Nilm** 2014, v. 22, n. November, p. 1–4, 2014. ISSN 2169-2637. Disponível em: [https://www.iss.uni-stuttgart.de/forschung/publikationen/barsim\\_nilmworkshop2014.pdf](https://www.iss.uni-stuttgart.de/forschung/publikationen/barsim_nilmworkshop2014.pdf).
- BATRA, N. et al. NILMTK: An open source toolkit for non-intrusive load monitoring. **e-Energy 2014 - Proceedings of the 5th ACM International Conference on Future Energy Systems**, n. April, p. 265–276, 2014.
- BATRA, N. et al. Towards reproducible state-of-the-art energy disaggregation. p. 193–202, 2019.
- FAUSTINE, A. et al. A Survey on Non-Intrusive Load Monitoring Methodies and Techniques for Energy Disaggregation Problem. 2017. Disponível em: <http://arxiv.org/abs/1703.00785>.
- F.SULTANEM. USING APPLIANCE SIGNATURES FOR MONITORING RESIDENTIAL LOADS AT METER PANEL LEVEL. **IEEE Transactions on Power Delivery**, v. 6, p. 4, 1991.
- HART, G. W. Nonintrusive Appliance Load Monitoring. **Proceedings of the IEEE**, v. 80, n. 12, p. 1870–1891, 1992. ISSN 15582256.
- HE, W.; CHAI, Y. An Empirical Study on Energy Disaggregation via Deep Learning. v. 133, p. 338–342, 2016.
- IQBAL, H. K. et al. A critical review of state-of-the-art non-intrusive load monitoring datasets. **Electric Power Systems Research**, Elsevier B.V., v. 192, n. May 2020, p. 106921, 2021. ISSN 03787796. Disponível em: <https://doi.org/10.1016/j.epsr.2020.106921>.
- KELLY, J.; KNOTTENBELT, W. Neural NILM: Deep neural networks applied to energy disaggregation. **BuildSys 2015 - Proceedings of the 2nd ACM International Conference on Embedded Systems for Energy-Efficient Built**, p. 55–64, 2015.
- KLEMENJAK, C.; MAKONIN, S.; ELMENREICH, W. Towards comparability in non-intrusive load monitoring: On data and performance evaluation. **2020 IEEE Power and Energy Society Innovative Smart Grid Technologies Conference, ISGT 2020**, 2020.

- LANGE, H.; BERGÉS, M. BOLT: Energy disaggregation by online binary matrix factorization of current waveforms. **Proceedings of the 3rd ACM Conference on Systems for Energy-Efficient Built Environments, BuildSys 2016**, p. 11–20, 2016.
- LIN, Y. H. Trainingless multi-objective evolutionary computing-based nonintrusive load monitoring: Part of smart-home energy management for demand-side management. **Journal of Building Engineering**, Elsevier Ltd, v. 33, n. June 2020, p. 101601, 2021. ISSN 23527102. Disponível em: <https://doi.org/10.1016/j.jobbe.2020.101601>.
- MARCHIORI, A. et al. Circuit-level load monitoring for household energy management. **IEEE Pervasive Computing**, v. 10, n. 1, p. 40–48, 2011. ISSN 15361268.
- MARQUÉS, A. I.; GARCÍA, V.; SÁNCHEZ, J. S. Exploring the behaviour of base classifiers in credit scoring ensembles. **Expert Systems with Applications**, v. 39, n. 11, p. 10244–10250, 2012. ISSN 09574174.
- MARTIN, B. W. A Review of Non-Intrusive Load Monitoring Tracking Approaches. p. 1–7, 2019.
- MARTINEZ, R.; PACHECO, D.; ROBERGS, D. NILM power disaggregation via artificial neural networks. **Proceeding of the 4th international workshop on non-intrusive load monitoring**, p. 1–4, 2018.
- MONZANI, R. C. Monitoramento não invasivo e identificação do consumo de energia individual de cargas residenciais. p. 148, 2016.
- NOH, H.; HONG, S.; HAN, B. Learning deconvolution network for semantic segmentation. **Proceedings of the IEEE International Conference on Computer Vision**, v. 2015 Inter, p. 1520–1528, 2015. ISSN 15505499.
- RENAUX, D. P. et al. Designing a novel dataset for non-intrusive load monitoring. **Brazilian Symposium on Computing System Engineering, SBESC**, v. 2018-Novem, p. 243–249, 2018. ISSN 23247894.
- RENAUX, D. P. B. et al. A dataset for non-intrusive load monitoring: Design and implementation. **Energies**, v. 13, n. 20, p. 1–35, 2020. ISSN 19961073.
- Reyes Lua, A. Location-aware Energy Disaggregation in Smart Homes. 2015.
- RIDI, A.; GISLER, C.; HENNEBERT, J. ACS-F2 - A new database of appliance consumption signatures. **6th International Conference on Soft Computing and Pattern Recognition, SoCPaR 2014**, IEEE, n. 11m, p. 145–150, 2014.
- SAMPLING, D. et al. NILM datasets - NILM. p. 9–12, 2021. Disponível em: [http://wiki.nilme.eu/index.php?title=NILM\\_datasets](http://wiki.nilme.eu/index.php?title=NILM_datasets).
- TOMÉ, M. d. C. Análise do impacto do chuveiro elétrico em redes de distribuição no contexto da tarifa horossazonal. p. 81, 2014.
- VERMA, A. et al. A Comprehensive Review on the NILM Algorithms for Energy Disaggregation. 2021. Disponível em: <http://arxiv.org/abs/2102.12578>.

---

XU, Y.; MILANOVIĆ, J. V. Artificial-intelligence-based methodology for load disaggregation at bulk supply point. **IEEE Transactions on Power Systems**, IEEE, v. 30, n. 2, p. 795–803, 2015. ISSN 08858950.